

3.1. Identificación del proyecto

Nombre del equipo: InmoMetrics

Nombre provisional del proyecto: Variación de precios y comparación de alternativas inmobiliarias en la CDMX.

Integrantes: Yadira, Enoc, Rafael.

Grupo: 301

Fecha: 21 septiembre de 2026

Enlace a la fuente seleccionada:

Fuente principal (Properati): <https://datamx.io/dataset/propiedades-venta-renta-properati>

Fuente secundaria (Kaggle): [Housing Prices in CDMX](#)

https://github.com/MRG301/proyecto_InmoMetrics_BI.git

Descripción del proyecto: Este proyecto analiza datos históricos de publicaciones de inmuebles (2016) y unidades económicas (DENUE 2018) para comprender cómo varían los precios anunciados en la Ciudad de México según su ubicación y características físicas. A través de un enfoque descriptivo, el análisis busca apoyar al analista comercial en la comparación de alternativas de compra cruzando el precio de los inmuebles con la densidad de servicios o negocios en la zona, sin inferir proyecciones de crecimiento futuro, plusvalía o retorno de inversión.

3.2. Problema organizacional y decisión

Contexto: Sector Inmobiliario, específicamente en el área de adquisiciones o análisis comercial.

Situación problemática: La empresa necesita evaluar diversas opciones de compra frente a un alto volumen de publicaciones inmobiliarias. Dado que existe un desfase temporal en las fuentes disponibles que impide inferir directamente crecimiento futuro, plusvalía o retorno de inversión, el problema radica en estructurar estos datos históricos para comprender con exactitud cómo fluctúan los precios anunciados en el mercado según la colonia y las características físicas de la propiedad.

Actores: responsable comercial o analista de adquisiciones inmobiliarias.

Decisión: Apoyar la comparación de alternativas de compra considerando ubicación, precio y características.

Alcance: El análisis abarca exclusivamente inmuebles en la Ciudad de México (a nivel de alcaldía y colonia) dentro de un periodo histórico delimitado por los datasets, evaluando la relación entre los precios anunciados y la densidad comercial como punto de comparación, sin realizar proyecciones financieras a futuro.

3.3. Pregunta de negocio

Pregunta principal: ¿Cómo varían los precios de los inmuebles entre las zonas analizadas de CDMX y qué diferencias se observan según sus características?

Desglose metodológico: La formulación de esta pregunta conecta directamente el fenómeno observable (los precios anunciados y sus diferencias) con la población objetivo (inmuebles ubicados en la CDMX). Esto permite realizar comparaciones claras basadas en la ubicación geográfica y las características físicas de la propiedad, con el fin de apoyar la decisión del analista comercial (comparar alternativas de compra), sin prometer causalidad, plusvalía o predicciones de crecimiento futuro.

3.4. Justificación del uso de BI

La implementación de un sistema de Inteligencia de Negocios para este proyecto se justifica por los siguientes motivos:

Transformación de gran volumen de datos: La situación requiere procesar archivos que en conjunto superan los 170,000 registros (Properati y Kaggle). El flujo de BI transformará estos datos crudos en métricas estandarizadas y útiles, como el precio promedio por metro cuadrado.

Comparaciones y cruces dinámicos: El responsable comercial necesita evaluar múltiples escenarios simultáneamente. BI permite crear un modelo donde se puedan filtrar y comparar las alternativas de compra cruzando la ubicación exacta con los atributos del inmueble (superficie y número de habitaciones), algo inviable en hojas de cálculo planas.

Reproducibilidad y trazabilidad: Construir un flujo automatizado (ETL y base de datos relacional) asegura que las reglas de limpieza sean trazables. Dado que las fuentes actuales presentan un desfase temporal, el sistema de BI dejará la arquitectura preparada para que, al disponer de una base de datos con precios actuales, el tablero se actualice sin tener que rediseñar el análisis desde cero.

Mejora frente a procesos manuales: Resuelve el problema de revisar archivos aislados y cifras sin una definición común, consolidando fuentes distintas en un único modelo semántico que alimenta un reporte visual e interactivo.

3.5. Dataset seleccionado y fuente alternativa

De acuerdo con la guía, se evalúa el dataset proveniente de Kaggle frente a una fuente alternativa (Properati 2016) para definir la mejor base analítica que responda a la nueva pregunta de negocio.

Criterio	Dataset de Kaggle (18,234 inmuebles) JPG	Fuente alternativa (Properati Data 2016) JPG
Relación con la pregunta	Alta. Contiene datos de ubicación en CDMX, precios y metros cuadrados que permiten comparar las alternativas.	Alta. Aporta el detalle de precios anunciados cruzados con características físicas como el número de habitaciones y superficie.
Formato y tamaño	Archivo .csv con 18,234 registros.	Archivos históricos .xlsx / .csv con 161,595 registros a nivel nacional.
Licencia y procedencia	Uso académico / Dominio público. Procedencia a verificar (presumiblemente extraído mediante web scraping de portales).	Datos Abiertos (Open Data). Base de datos oficial publicada por la plataforma inmobiliaria Properati.

Metadatos y diccionario	Documentación limitada, dependiente de la descripción original del usuario en la plataforma Kaggle.	Cuenta con variables estandarizadas y documentadas por la iniciativa de datos abiertos de Properati.
Cobertura y granularidad	Granularidad: Anuncio de propiedad. Cobertura: Limitado a la CDMX.	Granularidad: Anuncio de propiedad. Cobertura: Nivel nacional, con corte temporal exacto a septiembre de 2016.
Limitaciones y riesgos	Se debe verificar exhaustivamente su procedencia y el periodo exacto que cubre para darle validez temporal. Faltan algunas características físicas detalladas.	Existe un desfase temporal considerable; representa precios anunciados en 2016 y no permite inferir retornos ni valores actuales.
Decisión sobre la fuente	Aceptar con cautela (Sujeto a verificación temporal).	Aceptar como complemento robusto.

Decisión y justificación: Se decide aceptar ambas fuentes de manera combinada, pero delimitando estrictamente su alcance. El dataset de Kaggle cumple con el requisito de la plataforma y su enfoque exclusivo en la CDMX, pero atendiendo a la retroalimentación, se asume el compromiso de documentar y verificar su procedencia y periodo exacto. Properati 2016 se integrará debido a su volumen masivo y al detalle de sus variables físicas (como rooms), asumiendo en todo momento que es una "fotografía" histórica (precios de 2016) y no un modelo predictivo de plusvalía.

3.6. Inventario y primera lectura de los datos crudos

Inventario de archivos o tablas

Archivo o tabla	Filas y columnas	Formato	Unidad de observación	Cobertura	Función posible
properatimx2016.csv	161,595 filas / 24 columnas	CSV	Anuncio histórico de propiedad en venta	México (Corte exacto: Sep 2016)	Base principal para la comparación de precios anunciados y características físicas (ej. habitaciones).
housing_data_CDMX_v2.csv	18,234 filas / 13 columnas (aprox.)	CSV	Anuncio histórico de propiedad en venta	Exclusivamente Ciudad de México (Periodo histórico exacto a verificar)	Base de contraste y apoyo geográfico enfocado al 100% en la CDMX.
denue.xlsx	denue.xlsx	CSV	Unidad económica, establecimiento	Ciudad de México (Altas históricas hasta 2018)	Medir la densidad de servicios y negocios por zona

			comercial o de servicios		(colonia/alcaldía) para contrastar el nivel de consolidación con el precio inmobiliario.
--	--	--	--------------------------	--	--

Inventario de columnas principales

(Resumen de las variables relevantes para responder la pregunta de negocio)

Columna	Tipo aparente	Significado o unidad	Ejemplo o rango	Duda o problema visible
price	Numérico	Precio anunciado original del inmueble	1,500,000	Posible presencia de valores atípicos (outliers) muy altos o bajos, o inmuebles en otra moneda (USD).
surface_total_in_m2	Numérico	Superficie total de la propiedad en metros cuadrados	120	Presencia de valores nulos o celdas vacías que afectarán el cálculo del precio por m².
rooms	Numérico / Entero	Número de habitaciones (característica física)	3	Variable clave ausente en el set de Kaggle y con posibles nulos en Properati.
place_name / location	Texto (String)	Nombre de la colonia o zona de ubicación	"Polanco"	Cadenas de texto no estandarizadas, sucias o con errores tipográficos por ser ingresadas por el usuario.
nombre_act	Texto	Actividad o giro del establecimiento.		Nombres muy largos o específicos; requerirá agruparse por categorías
municipio / nomb_asent	Texto	Alcaldía y Colonia del establecimiento.		Presenta aprox 149 valores nulos en el nombre del asentamiento. El texto está todo en mayúsculas, lo que dificultará el cruce con Properati.
latitud / longitud	Texto	Coordenadas geográficas exactas del negocio.		Tienen precisión alta, útiles para generar mapas de calor, pero requieren validación espacial.

Señales visibles y dudas iniciales Con base en la inspección preliminar sin aplicar limpieza profunda, se documentan los siguientes hallazgos:

Desfase temporal e incertidumbre en fechas: Properati indica claramente que es una base de septiembre de 2016. Por otro lado, la fuente de Kaggle no especifica de inmediato su periodo temporal de recolección. Esto refuerza la decisión de analizar la variación histórica de precios y no proyectar un mercado futuro.

Discrepancia en variables descriptivas: Se observa que la base de Properati incluye el número de recámaras (rooms), pero la base de Kaggle parece carecer de esta granularidad física para todos sus registros, lo que podría complicar la comparación homogénea entre ambas fuentes.

Valores nulos: Existen registros donde las variables de precio y superficie están en blanco, lo que obligará a establecer reglas de descarte o imputación durante el Análisis Exploratorio de Datos con Python en etapas posteriores.

Ambigüedad espacial: La base cruda agrupa ubicaciones en un formato de texto largo (ej. place_with_parent_names en Properati). Será necesario extraer la colonia y alcaldía exacta para poder responder "cómo varían los precios de los inmuebles entre las zonas analizadas de CDMX".

3.7. Plan analítico preliminar

Este plan conecta la pregunta de negocio ajustada con lo que los datos permiten observar estadísticamente. Se parte de la unidad básica (un anuncio inmobiliario histórico) para estructurar cómo se filtrarán y calcularán las variaciones de precios recomendadas.

Matriz de dimensiones, medidas y KPIs preliminares

Necesidad analítica	Evento y granularidad	Dimensiones	Medidas base	Métrica o KPI y cálculo preliminar	Fuente, columnas y duda
Comparar alternativas de compra por zona territorial.	Anuncio de propiedad en venta publicado (un registro).	Alcaldía, Colonia (place_name).	Precio total (price), Metros cuadrados (surface_total_in_m2).	Precio promedio por metro cuadrado: Suma de precios / Suma de m ² por zona.	Properati y Kaggle (price, surface_total_in_m2). Duda: Valores atípicos que sesguen el promedio.
Evaluar las diferencias de precio según las características físicas del inmueble.	Anuncio de propiedad en venta publicado (un registro).	Número de habitaciones (rooms).	Precio total anunciado (price).	Diferencial de precio por habitación: Comparación del precio promedio entre inmuebles	Properati (price, rooms). Duda: La variable rooms no está confirmada en el set de Kaggle.

				de 1, 2 y 3 recámaras .	
Detectar concentración de opciones accesibles.	Anuncio de propiedad en venta publicado (un registro).	Alcaldía, Colonia.	Conteo de registros (anuncios).	Volumen de alternativas de compra: Conteo de propiedades cuyo precio/m ² está por debajo del promedio de su alcaldía.	Properati y Kaggle. Duda: Desfase temporal en el volumen registrado.

Preguntas analíticas secundarias verificables: Para ayudar a responder la pregunta principal sobre cómo varían los precios y apoyar la comparación, se proponen las siguientes preguntas secundarias verificables con las variables disponibles:

¿Qué colonias de la CDMX presentan los precios promedio por metro cuadrado más bajos para propiedades con características similares (ej. 2 habitaciones)?

¿Cómo se modifica el precio promedio de un inmueble al incrementarse el número de recámaras dentro de una misma alcaldía?

¿Qué porcentaje de los anuncios clasificados en las bases históricas cuenta con características físicas completas (superficie y recámaras) que permitan una comparación equitativa?

3.8. Arquitectura propuesta de la cadena BI

Para este proyecto, el flujo de los datos desde su origen hasta la toma de decisiones seguirá la cadena tecnológica establecida, adaptada específicamente para el análisis de los anuncios inmobiliarios y la comparación de alternativas de compra.

Esquema general de la trayectoria: Datos crudos históricos (Properati/Kaggle) → PYTHON (Perfilamiento y Limpieza) → ETL (Carga) → POSTGRESQL (Almacenamiento Relacional) → SQL Analítico (Cálculo de Promedios) → POWER BI (Dashboard de Comparación) → Decisión (Analista Comercial).

Responsabilidades por etapa de la arquitectura:

Etapa	Entrada prevista	Responsabilidad	Salida o evidencia prevista
Datos crudos	Archivos originales properatimx2016.csv y housing_data_CDMX_v2.csv.	Conservar el origen, la versión y la estructura original sin alterar	Copia alojada en la carpeta data/raw/ del repositorio, junto con

		ni modificar una sola celda de los archivos descargados.	este inventario inicial.
PYTHON	Datos crudos identificados en la etapa anterior.	Leer, perfilar, imputar datos faltantes (ej. nulos en rooms o superficie), limpiar el texto de las ubicaciones (place_name) para aislar las colonias de la CDMX y realizar un análisis exploratorio.	Notebooks de Jupyter (o scripts) documentados, resultados de validación y archivos .csv preparados/limpios.
ETL	Datos preparados desde Python y reglas de transformación documentadas.	Organizar de manera reproducible la extracción de los datos limpios, su transformación final y la carga hacia la base de datos.	Proceso de carga ejecutable, bitácora de errores y separación clara entre los datos crudos y los listos para carga.
POSTGRESQL	Datos listos para la carga generados por el proceso ETL.	Almacenar las tablas relacionales (ej. dimensiones de ubicación y tabla de hechos de los anuncios clasificados) manteniendo las restricciones y la calidad de los datos.	Tablas en modelo relacional, relaciones establecidas mediante claves y registros de carga exitosos.
SQL analítico	Tablas relacionadas y almacenadas en PostgreSQL.	Cruzar, agrupar y calcular las métricas verificables (ej. calcular el precio promedio por metro cuadrado agrupado por alcaldía y número de recámaras) para responder a la pregunta de negocio.	Consultas analíticas probadas y vistas (Views) listas para ser consumidas por la herramienta de visualización.

POWER BI	Vistas analíticas provenientes de PostgreSQL.	Construir el modelo semántico final y comunicar los resultados a través de filtros interactivos (por zona o características) y mapas/gráficos comparativos.	Reporte o Dashboard trazable y funcional conectado directamente a la base de datos.
Decisión	Resultados interpretados desde el dashboard de Power BI.	Permitir al analista comercial identificar cómo varían los precios y apoyar su labor de comparar alternativas de compra basándose en datos medibles de precio y características.	Recomendación o criterio de decisión técnica con los riesgos históricos explícitos.

3.9. Riesgos, límites y dudas abiertas

En cumplimiento con la guía del proyecto, se reconoce explícitamente que ocultar límites resta calidad al análisis. A continuación, se detallan los riesgos identificados, especialmente aquellos señalados en la retroalimentación de la revisión presencial:

Riesgo o duda	Evidencia disponible	Efecto posible	Cómo y cuándo se atenderá
Desfase temporal e inferencia indebida	La fuente principal (Properati) corresponde a septiembre de 2016 y la retroalimentación señala un claro desfase temporal.	Riesgo de interpretar erróneamente que los datos reflejan el mercado actual o intentar predecir plusvalía y retornos de inversión.	Atendido mediante reorientación: El proyecto ya ajustó su alcance para enfocarse exclusivamente en la variación histórica de precios. Se mantendrá este límite interpretativo durante todo el semestre.
Procedencia indefinida del dataset secundario	El dataset de Kaggle (18,234 inmuebles) carece de metadatos explícitos sobre el periodo exacto de extracción.	Invalidez técnica de la fuente si los datos corresponden a un periodo incompatible con la base principal o provienen de una extracción defectuosa.	Pendiente para siguiente revisión: Se verificará exhaustivamente la procedencia y el periodo de este dataset investigando la fuente original en Kaggle antes de iniciar la etapa de Python.

Valores faltantes en características físicas	La revisión inicial muestra nulos en <code>surface_total_in_m2</code> y ausencia documentada de rooms en el set secundario.	Imposibilidad de calcular el precio promedio por metro cuadrado y errores al comparar alternativas de compra por características.	Durante el uso de Python (semanas 5-8), se documentarán reglas estrictas para imputar valores o descartar las filas que no permitan el cruce.
Ambigüedad en la definición geográfica (Granularidad)	La ubicación (<code>place_name</code>) viene en formato de texto libre o cadenas compuestas, propensas a errores tipográficos.	Agrupaciones incorrectas al momento de calcular promedios por alcaldía o colonia mediante SQL.	Se aplicará limpieza y separación de cadenas de texto en Python. El dataset del INEGI se usará exclusivamente como catálogo de validación territorial si es necesario para normalizar nombres.

3.10. Conclusión de viabilidad y siguientes pasos

Conclusión de viabilidad: El proyecto se dictamina como viable con ajustes, siempre y cuando se respete la reorientación del alcance y la fuente.

Qué sí puede atenderse con la fuente: Con los datasets seleccionados (Properati y Kaggle) es posible responder cómo varían los precios históricos de los inmuebles entre las zonas analizadas de la CDMX y comparar las diferencias según sus características físicas (superficie y recámaras).

Qué NO se puede concluir: Debido al desfase temporal de las fuentes, está estrictamente descartado realizar afirmaciones o proyecciones sobre plusvalía, crecimiento futuro o retorno de inversión actual.

Viabilidad técnica en el curso: El proyecto es manejable dentro de la cadena tecnológica del semestre porque la estructura de los datos crudos (archivos CSV con precios, ubicación y características) se adapta perfectamente a la limpieza en PYTHON, el modelado relacional en POSTGRESQL y la visualización comparativa interactiva en POWER BI.

Riesgos a resolver antes de interpretar: Se debe comprender a fondo las variables del dataset secundario de Kaggle, verificando qué representa cada registro y qué periodo exacto cubre, para evitar mezclar temporalidades incompatibles con la base de 2016.

Primeras tareas técnicas (Semanas 5 a 8):

Documentar formalmente la procedencia del dataset de 18,234 inmuebles.

Cargar los archivos CSV originales en entornos de PYTHON (Jupyter Notebooks) para el perfilamiento inicial.

Identificar y cuantificar la proporción real de valores nulos en columnas críticas como la superficie y las habitaciones.

Diseñar la lógica para extraer y limpiar los nombres de las colonias y alcaldías de las cadenas de texto crudas de ubicación.